Лабораторная работа №7

по дисциплине

«Разработка информационно-аналитических систем»

Тема:

«Аналитика графов и временных рядов»

Студент: _____

Группа: _____

Преподаватель: _____

Москва, 2026

Цель, теория и постановка задачи

Цель работы: изучить методы анализа динамических графов и временных рядов на реальном наборе событий взаимодействия между узлами, представить графовые характеристики как временные ряды, проверить их стационарность, выполнить декомпозицию и прогнозирование.

Краткое теоретическое обоснование. Динамический граф — это граф, структура которого меняется во времени. Для каждого временного окна можно строить отдельный граф-снимок и вычислять его характеристики: среднюю степень, плотность, коэффициент кластеризации, число компонент связности, диаметр и центральность по посредничеству.

Временной ряд — последовательность значений, упорядоченных во времени. Для временных рядов важны проверка стационарности, выделение тренда и сезонности, а также прогнозирование. В лабораторной работе использовались тест Дики–Фуллера, аддитивная декомпозиция, скользящее среднее и модель ARIMA.

Постановка задачи:

1. Заменить синтетический датасет реальным.

2. Разбить временную шкалу на равные интервалы.

3. Для каждого окна построить граф.

4. Рассчитать графовые метрики и представить их в виде временных рядов.

5. Проверить стационарность, выделить тренд и сезонность, построить прогноз.

6. Дополнительно проанализировать центральность по посредничеству, корреляцию метрик и отношение in/out степеней.

Описание данных. Использован датасет CollegeMsg: 59,835 событий, 1,899 узлов, период наблюдения с 15.04.2004 по 26.10.2004. Для анализа выбраны равные окна длиной 7 дней.

Методика выполнения работы

Этапы выполнения работы:

1. Загрузка реального датасета из файла CollegeMsg.txt.gz и преобразование UNIX-времени в datetime.

2. Разбиение событий на равные недельные интервалы времени. Это исправляет типичную ошибку, когда данные режут по фиксированному числу событий, а не по шкале времени.

3. Построение для каждого окна неориентированного и ориентированного графа.

4. Расчёт набора метрик: avg_degree, density, avg_clustering, n_components, diameter, betweenness_mean, betweenness_max, in_out_ratio_mean.

5. Формирование отдельной таблицы с центральностью по посредничеству для каждой вершины во всех окнах.

6. Построение временных рядов, тест Дики–Фуллера, аддитивная декомпозиция, сглаживание скользящим средним и прогноз ARIMA(1,1,1).

Ключевые фрагменты кода:

load_events_file(...): чтение файла, нормализация временных меток, сортировка событий.

split_into_time_windows(...): определение window_id по разности timestamp и начала временной шкалы.

compute_metrics_table(...): вычисление графовых метрик и формирование таблицы centrality по вершинам.

fit_arima(...): разделение ряда на train/test, прогноз на тестовой выборке и несколько шагов вперёд.

Результаты и интерпретация

Основные результаты анализа:

1. Получено 28 временных окон.

2. Средняя степень вершины: 2.9706, диапазон от 1.3714 до 7.5646.

3. Средняя плотность графа: 0.0119.

4. Средний коэффициент кластеризации: 0.0219.

5. Среднее число компонент связности: 16.5714, минимум 2, максимум 26.

6. Диаметр не был вычислен ни в одном окне, поскольку граф оставался несвязным на всём периоде наблюдения.

7. Среднее значение betweenness_mean: 0.0085.

8. Среднее значение in_out_ratio_mean: 0.8953.

9. Вершина с наибольшей средней центральностью по посредничеству: 1624.0 (0.067281).

Интерпретация. В начале периода сеть была существенно плотнее, затем avg_degree и density снижались, а число компонент возрастало. Это означает постепенную фрагментацию сети и снижение интенсивности связей.

Топ-5 окон по средней степени вершины

window_id	time_start	time_end	avg_degree	density	n_components
3	29.04.2004	06.05.2004	7.5646	0.0124	4
4	06.05.2004	13.05.2004	6.8658	0.0087	2
6	20.05.2004	27.05.2004	6.4058	0.0072	11
5	13.05.2004	20.05.2004	6.0564	0.0081	6
2	22.04.2004	29.04.2004	5.5413	0.0148	2

Топ-5 вершин по средней centrality betweenness

node	mean_betweenness
1624	0.067281
9	0.057146
105	0.054554
1713	0.052062
249	0.038244

Стационарность и прогнозирование

Результаты проверки стационарности и прогноза извлечены из итоговой сводки.

Лабораторная работа №7
Источник данных: /Users/rhktrlwmd/Documents/New project/data/raw/CollegeMsg.txt.gz
Размер окна: 7D
Количество окон: 28

ADF для avg_degree:
  statistic = -2.9708572548714423
  p_value = 0.03770705558213111
  conclusion = Стационарный

ADF для in_out_ratio_mean:
  statistic = 1.510315502535707
  p_value = 0.9975619362820367
  conclusion = Нестационарный

ADF для betweenness вершины 1624:
  statistic = 2.360106692317331
  p_value = 0.9989902815932167
  conclusion = Нестационарный

Корреляция avg_degree и n_components: -0.8042202472735333
Декомпозиция построена: да

ARIMA:
  MAE = 0.35390919409995986
  RMSE = 0.38536307515387885

Интерпретация. Ряд avg_degree признан стационарным, тогда как среднее отношение in/out степеней и временной ряд центральности вершины-лидера нестационарны. Это означает, что общая связность сети меняется относительно умеренно, а направленность взаимодействий и влияние отдельных посредников меняются значительно сильнее.

По ARIMA видно, что модель улавливает общий нисходящий уровень ряда, но на тестовой части систематически завышает значения. Поэтому прогноз можно считать рабочим, но умеренно точным.

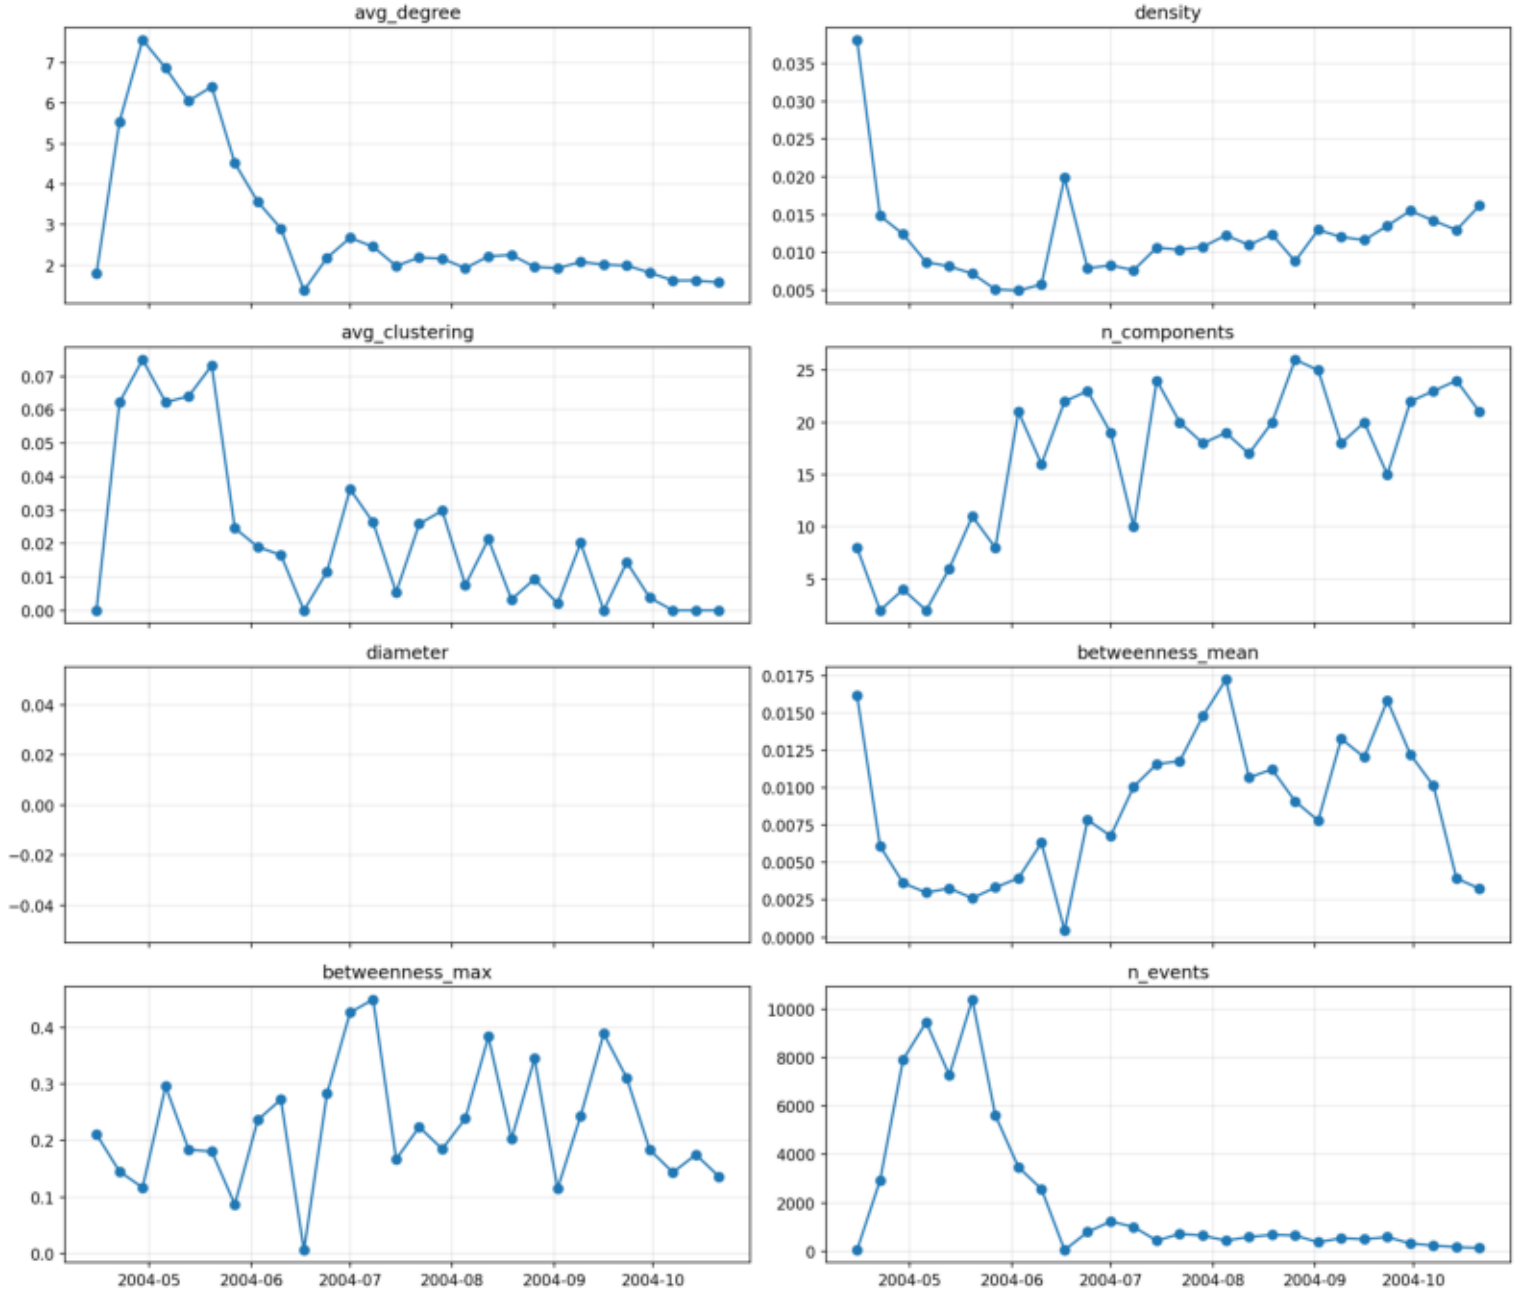
Сравнение ARIMA с фактическими значениями

time	actual	predicted	abs_error
23.09.2004	1.9865	2.0867	0.1002
30.09.2004	1.8136	2.0704	0.2568
07.10.2004	1.6174	2.0739	0.4565
14.10.2004	1.6190	2.0732	0.4541
21.10.2004	1.5714	2.0733	0.5019

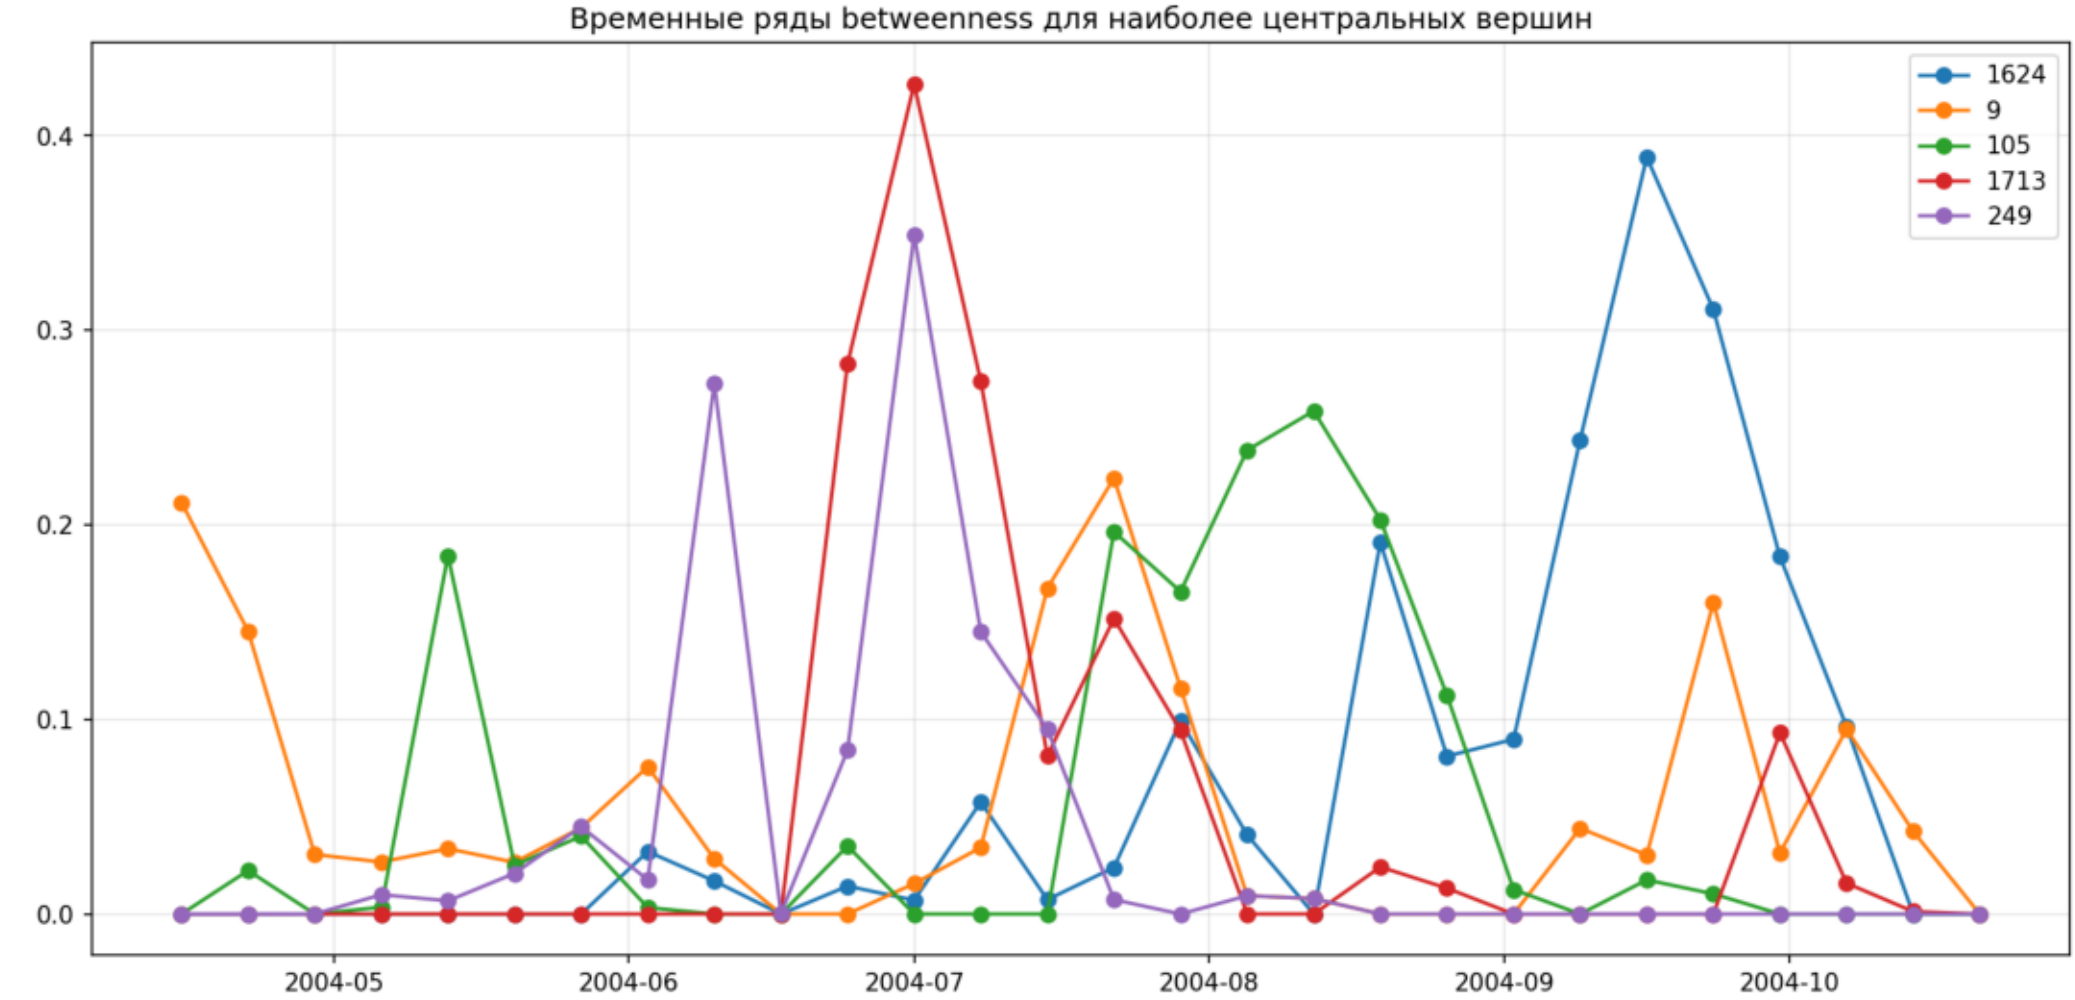
Прогноз ARIMA на 4 шага вперёд

time	forecast
28.10.2004	1.4344
04.11.2004	1.4634
11.11.2004	1.4572
18.11.2004	1.4585

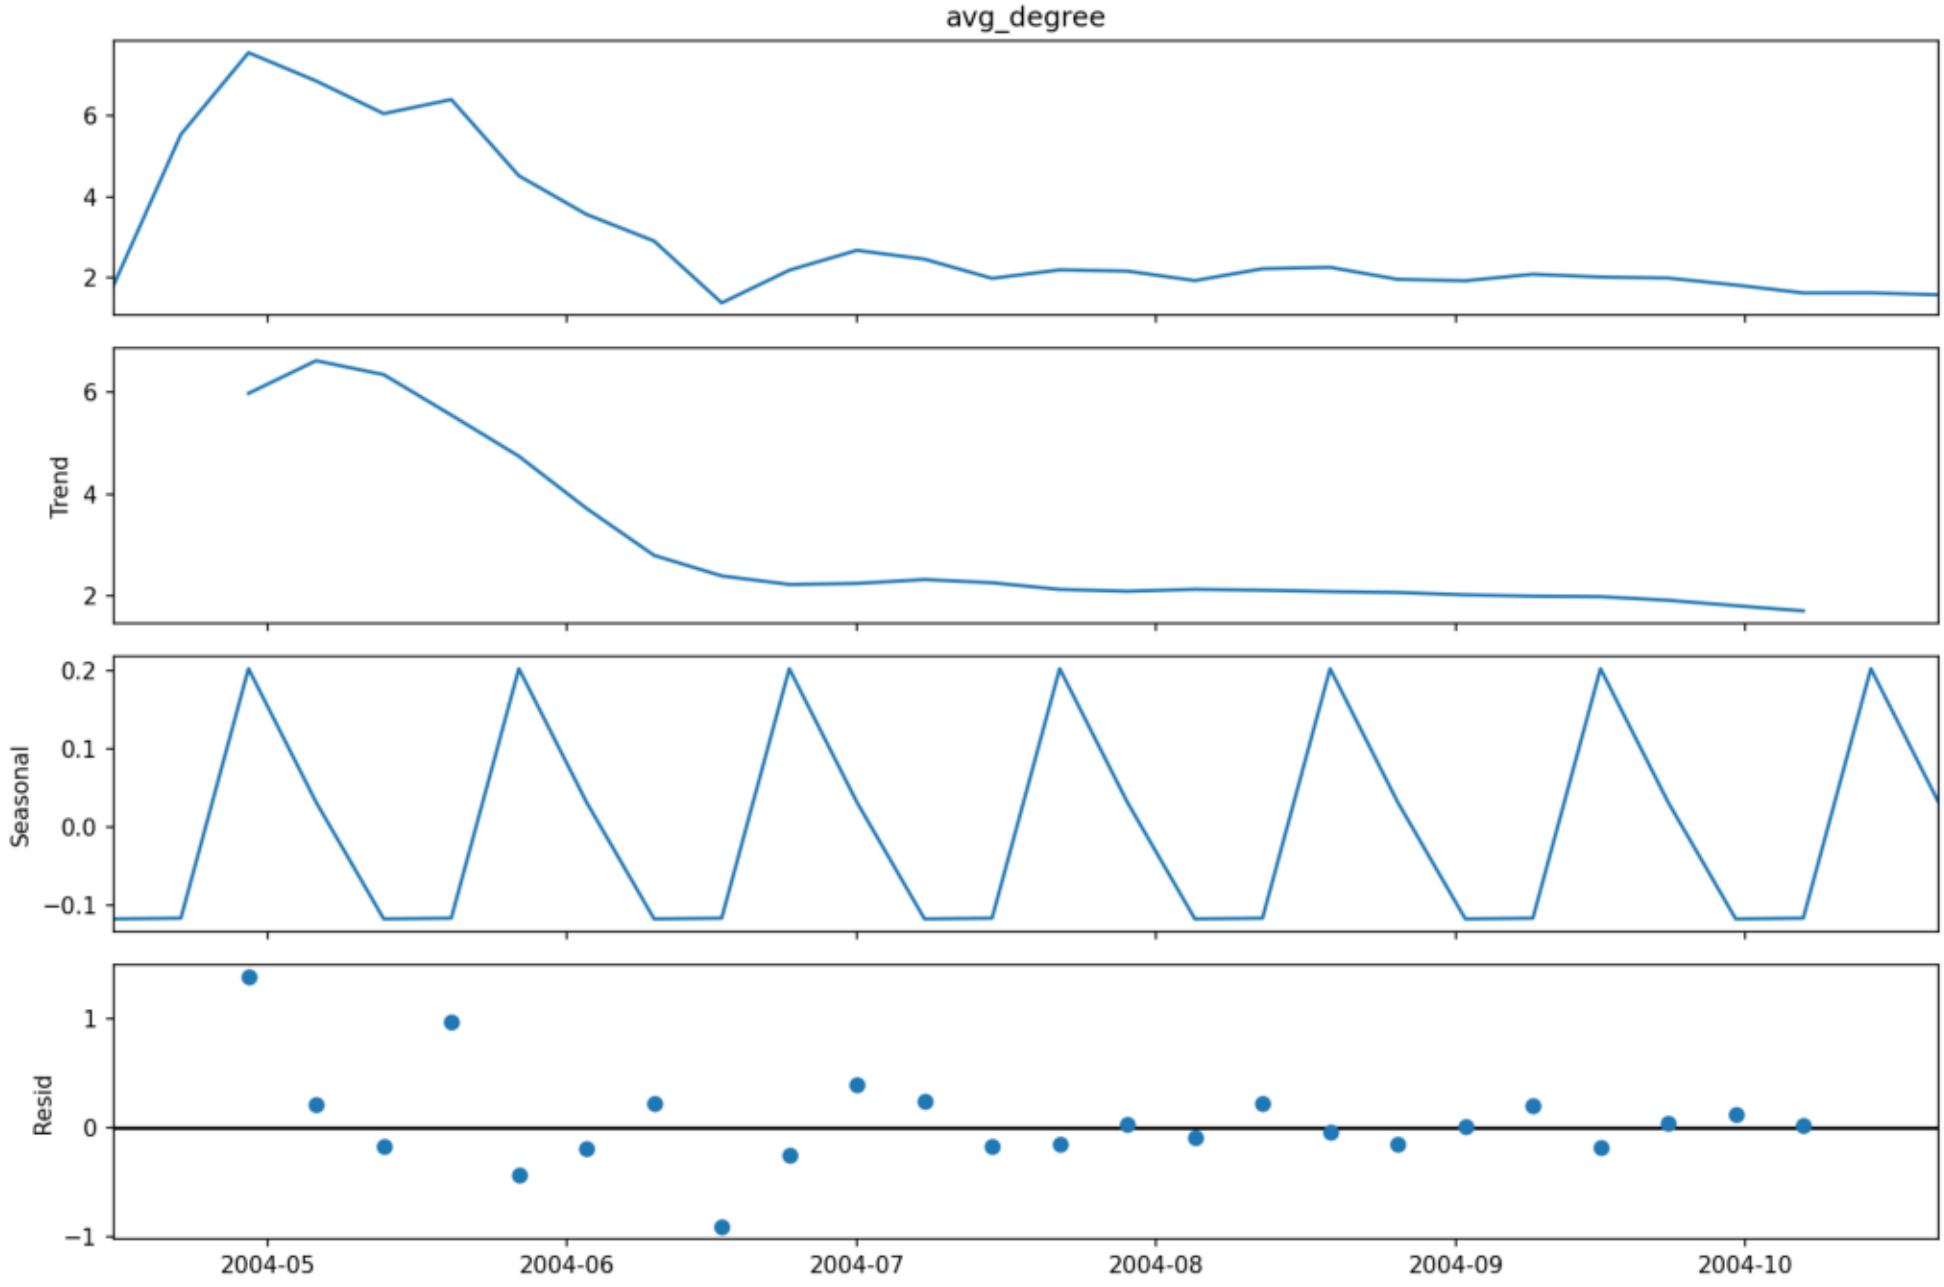
Временные ряды графовых метрик



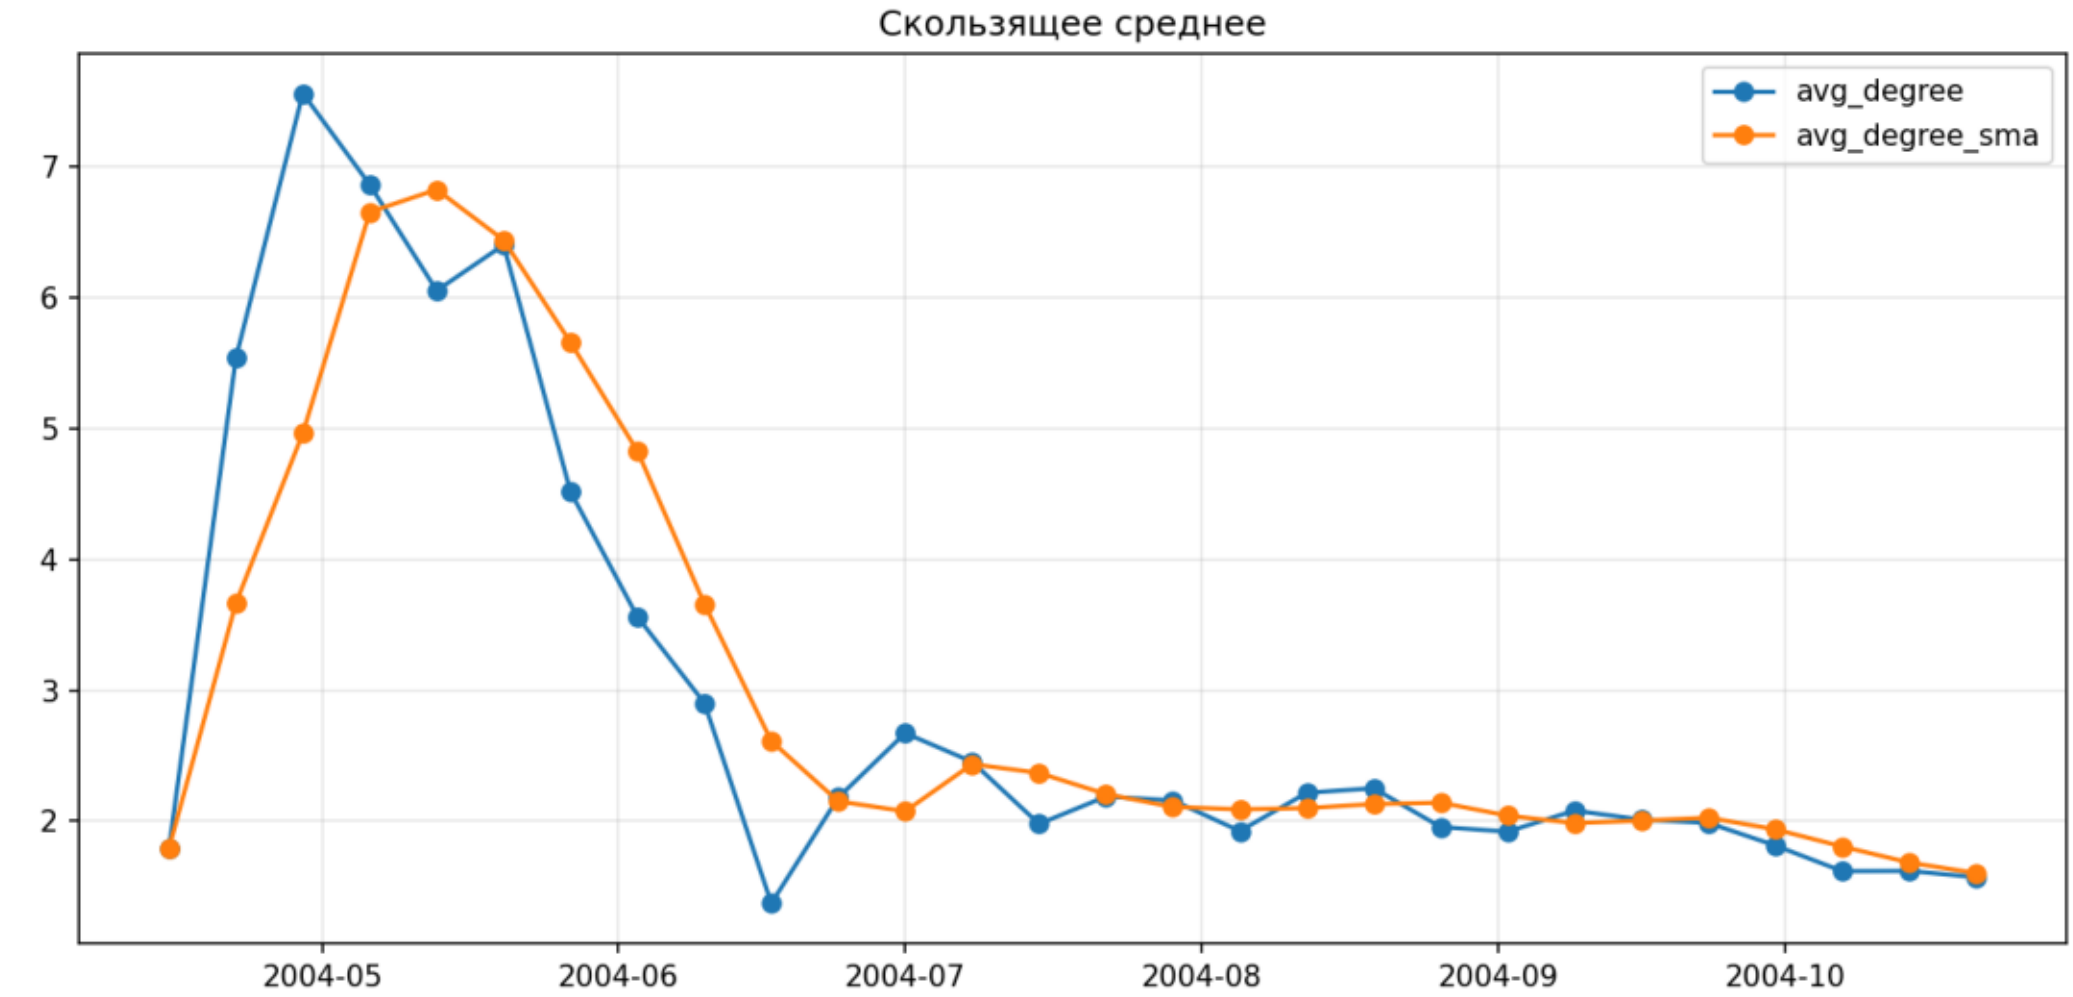
Временные ряды betweenness для ключевых вершин



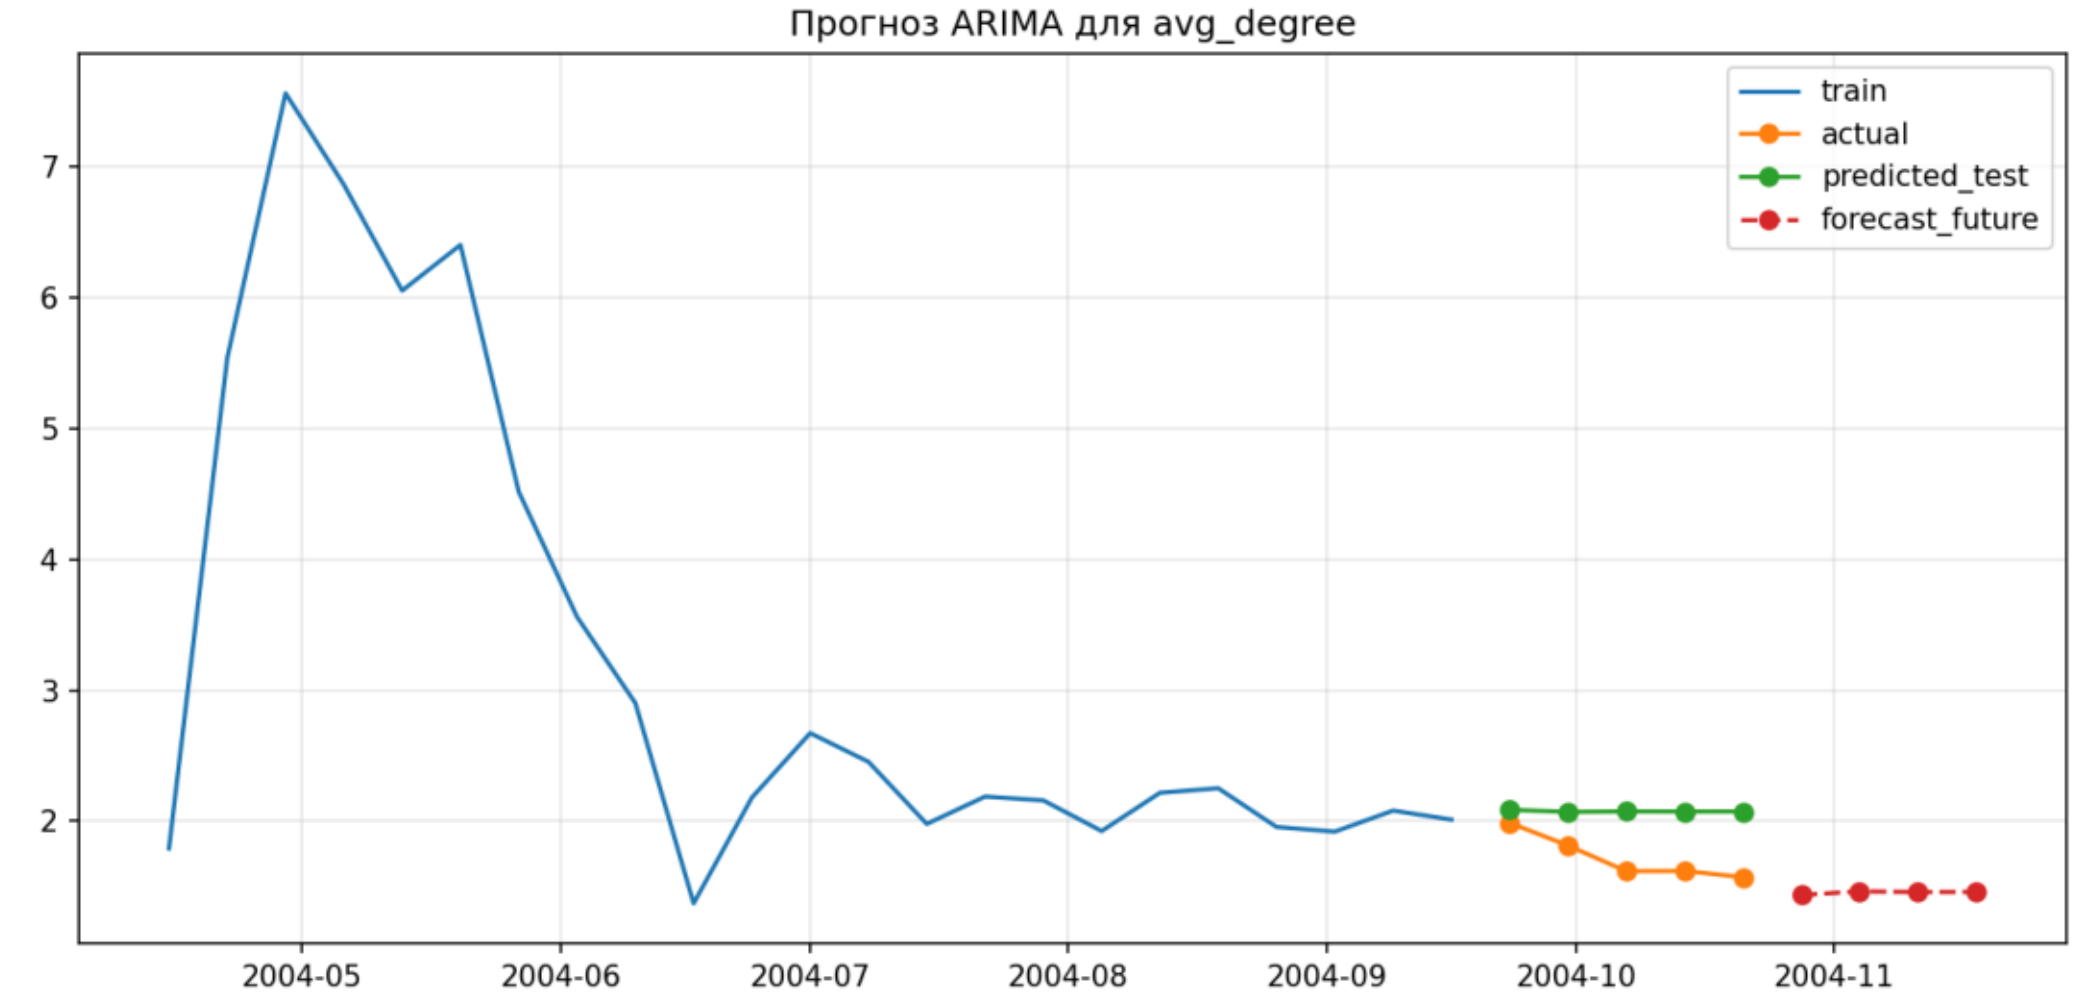
Декомпозиция ряда avg_degree



Скользящее среднее для avg_degree



Прогноз ARIMA



Выводы

Выводы:

1. Лабораторная работа выполнена на реальном датасете CollegeMsg, как требовалось в задании.

2. Разбиение данных выполнено по равным временным интервалам, что соответствует постановке задачи.

3. Структура графа со временем стала более разреженной: средняя степень и плотность снижались, а число компонент связности росло.

4. Коэффициент кластеризации оставался низким, поэтому устойчивые локальные группы выражены слабо.

5. Сильная отрицательная корреляция между avg_degree и n_components подтверждает, что рост числа связей уменьшает фрагментацию сети.

6. Анализ betweenness показал наличие вершин-посредников, но их влияние заметно менялось во времени.

7. Ряд avg_degree оказался стационарным, а in_out_ratio_mean и betweenness вершины-лидера — нестационарными.

8. Модель ARIMA дала приемлемый прогноз по тренду, но без высокой точности на тестовой выборке.

1. Что такое динамический граф и какими способами его можно представить в памяти?

Динамический граф — это граф, структура которого меняется во времени: появляются и исчезают рёбра, а иногда и вершины. В данной работе граф задаётся потоком событий вида `source, target, timestamp`, а затем для каждого временного окна строится отдельный снимок сети.

Основные варианты представления в памяти:

1. Последовательность снимков графа по окнам времени.
2. Список событий или рёбер с временными метками.
3. Единый граф с временными атрибутами у рёбер и вершин.
4. Многослойный граф, где каждый слой соответствует отдельному моменту или интервалу времени.

Для лабораторной удобнее всего хранить исходные события, а затем агрегировать их в окна фиксированной длины.

2. Какие графовые метрики наиболее информативны для отслеживания эволюции сети?

Для анализа динамики сети особенно полезны:

1. Средняя степень вершины.
2. Плотность графа.
3. Средний коэффициент кластеризации.
4. Число компонент связности.
5. Диаметр.
6. Центральность по посредничеству.
7. Для ориентированных графов — входящие и исходящие степени, а также их отношение.

В этой работе наиболее показательными оказались `avg_degree`, `n_components`, `density` и `betweenness`, потому что именно они лучше всего отражали укрупнение и распад компонент, а также появление узлов-посредников.

3. Как проверить стационарность временного ряда и зачем это нужно?

Стационарность проверяют визуально и статистическими тестами. На практике чаще всего используют:

1. Тест Дики–Фуллера.
2. Анализ поведения среднего и дисперсии на разных участках ряда.
3. Графики автокорреляции и частной автокорреляции.
4. Анализ тренда и сезонности после декомпозиции.

Это нужно, потому что многие модели прогнозирования, включая ARIMA, предполагают стабильность статистических свойств ряда. Если ряд нестационарен, модель может давать смещённый прогноз.

4. Что показывает тест Дики–Фуллера? Интерпретация p-value.

Тест Дики–Фуллера проверяет гипотезу о наличии единичного корня.

1. Нулевая гипотеза `H0`: ряд нестационарен.
2. Альтернативная гипотеза `H1`: ряд стационарен.

Интерпретация:

1. Если `p-value < 0.05`, нулевая гипотеза отвергается, ряд считают стационарным.
2. Если `p-value >= 0.05`, оснований отвергнуть нестационарность нет.

В моём эксперименте ряд `avg_degree` оказался стационарным (`p = 0.0377`), а `in_out_ratio_mean` и временной ряд центральности вершины `1624` оказались нестационарными.

5. Чем отличаются аддитивная и мультипликативная модели декомпозиции?

Аддитивная модель:

`Y(t) = Trend(t) + Seasonality(t) + Residual(t)`

Она подходит, когда амплитуда сезонных колебаний примерно постоянна.

Мультипликативная модель:

`Y(t) = Trend(t) * Seasonality(t) * Residual(t)`

Она подходит, когда амплитуда сезонности зависит от уровня ряда.

В лабораторной использовалась аддитивная модель, так как для выбранных графовых метрик её интерпретация проще и устойчивее.

6. Какие методы прогнозирования временных рядов вы знаете?

Основные методы:

1. Скользящее среднее.
2. Экспоненциальное сглаживание.
3. AR, MA, ARMA, ARIMA, SARIMA.
4. Prophet.
5. Регрессионные модели с временными признаками.
6. Нейросетевые модели: RNN, LSTM, трансформеры.

В лабораторной использовались два подхода:

1. Скользящее среднее для сглаживания ряда.
2. ARIMA для прогноза на несколько шагов вперёд и сравнения с фактическими значениями.